

PREDLOG PROJEKTA

Predmet: Računarska inteligencija

Članovi tima: Teodora Aleksić, SV7/2023 i Lenka Nikolić, SV16/2023

1. Naziv teme

Prostorno-vremenska analiza i predikcija indeksa kvaliteta vazduha (AQI) u Srbiji primenom modela mašinskog učenja

2. Definicija problema i motivacija

Aerozagađenje u urbanim i industrijskim centrima Srbije (kao što su Beograd, Novi Sad, Bor, Pančevo, Smederevo, Valjevo...) predstavlja jedan od najkritičnijih ekoloških i zdravstvenih izazova našeg društva. Koncentracije suspendovanih čestica PM2.5 i PM10 redovno i višestruko premašuju granične i bezbedne vrednosti propisane od strane Svetske zdravstvene organizacije (WHO). Dugotrajna izloženost ovim zagađujućim materijama direktno je povezana sa povišenom stopom respiratornih, kardiovaskularnih i malignih oboljenja kod stanovništva svih starosnih grupa.

Postojeći zvanični državni sistemi monitoringa deluju isključivo reaktivno: oni konstatuju, beleže i objavljuju podatke o zagađenju tek nakon što je ono već prisutno u vazduhu, i to ne stalno i ne uvek sa ispravnim podacima.

Glavna motivacija ovog projekta jeste prelazak sa reaktivnog na proaktivni (preventivni) model donošenja odluka. Razvojem inteligentnog sistema zasnovanog na algoritmima računarske inteligencije, koji može da prognozira skokove zagađenja 24 časa unapred, ostvaruje se visoka praktična i društvena primenljivost kroz:

- Preventivno delovanje građana: Pravovremena informacija omogućava osetljivim kategorijama stanovništva (deca, astmatičari, trudnice, starije osobe) da minimizuju izloženost i svesno prilagode svoje aktivnosti na otvorenom prostoru.
- Sisteme rane najave za lokalne samouprave: Donosioci odluka i ekološki inspektori dobijaju matematički opravdan i validan alat za uvođenje preventivnih mera pre nego što zagađenje dostigne kritični pik (npr. privremena izmena ili restrikcija teškog saobraćaja, prilagođavanje režima rada lokalnih toplana i industrijskih kompleksa).

Usklađujući se sa teorijskim osnovama mašinskog učenja, ovaj problem formalno definišemo kao trojku $\langle P, T, E \rangle$ prema Mitchell-ovoj definiciji:

- Performansa (P): Minimizacija greške u predikciji numeričkih vrednosti i maksimizacija tačnosti prepoznavanja kritičnih klasa zagađenja, merena statističkim metodama.

- Zadatak (T): Predikcija kontinualnih vrednosti zagađujućih materija i klasifikacija opšteg indeksa kvaliteta vazduha (AQI) za vremenski korak $t + 24h$.
- Iskustvo (E): Set satnih merenja aerozagađenja koji obuhvata masovne podatke prikupljane tokom 10 godina rada mernih stanica.

3. Skup podataka (Dataset)

Za potrebe realizacije projekta formiran je robustan skup podataka koji obuhvata satna merenja u kontinuitetu od 10 godina, čime se obezbeđuje statistička reprezentativnost i uspešno obuhvatanje svih sezonskih varijacija i višegodišnjih klimatskih trendova. Podaci su preuzeti preko [Open-Meteo Air Quality Historical API](#)-ja, koji objedinjuje podatke satelitskog osmatranja (Copernicus CAMS) i merenja sa prizemnih automatskih stanica Agencije za zaštitu životne sredine (SEPA).

Broj datoteka i instanci: Skup se sastoji od 28 zasebnih CSV datoteka (jedna za svaki analizirani grad u Srbiji). Svaka datoteka sadrži oko 87.600 hronološki sekvencijalnih redova (instanci), što ukupno čini preko 2.450.000 zapisa na nivou celog projekta.

Obuhvaćene lokacije: Analizira se 28 gradova i ključnih lokacija: Beočin, Beograd, Bor, Čačak, Kosjerić, Kostolac, Kragujevac, Kraljevo, Kruševac, Kikinda, Kopaonik, Loznica, Negotin, Niš, Novi Pazar, Novi Sad, Pančevo, Paraćin, Pirot, Smederevo, Sremska Mitrovica, Subotica, Šabac, Užice, Valjevo, Vranje, Vršac i Zaječar.

Struktura atributa u svakom CSV fajlu sadrži sledeća obeležja:

1. date: Vremenska odrednica merenja, odnosno datum i vreme merenja (DateTime indeks u formatu YYYY-MM-DD HH:MM). Predstavlja ključni atribut za vremensko indeksiranje i praćenje sekvencijalnog toka serije.
2. PM10: Koncentracija suspendovanih čestica prečnika do 10 mikrona izražena u mikrogramima po kubnom metru ($\mu g/m^3$). Značajan indikator industrijskog i zimskog zagađenja usled sagorevanja.
3. PM2.5: Koncentracija finih suspendovanih čestica prečnika do 2.5 mikrona izražena u $\mu g/m^3$. Ovo je primarni zdravstveni indikator i najvažniji atribut za analizu uticaja vazduha na zdravlje ljudi.
4. carbone_monoxide (CO): Koncentracija ugljen-monoksida u $\mu g/m^3$. Kovarijabla koja je primarni indikator zagađenja čiji je izvor nepotpuno sagorevanje, tj saobraćaj i industrija.
5. sulphur_dioxide (SO2): Koncentracija sumpor-dioksida u $\mu g/m^3$. Kovarijabla koja služi kao jasan indikator sagorevanja lignita i uglja sa visokim procentom sumpora u toplanama i termoenergetskim postrojenjima.
6. ozone (O3): Koncentracija prizemnog ozona u $\mu g/m^3$. Kovarijabla koja predstavlja sekundarni polutant sa specifičnim, izraženim letnjim pikovima usled fotohemijskih reakcija pod uticajem UV zračenja.
7. nitrogen_dioxide (NO2): Koncentracija azot-dioksida u $\mu g/m^3$. Kovarijabla koja je primarni indikator zagađenja čiji je izvor intenzivan drumski saobraćaj.

Ciljna obeležja: Kontinualna numerička vrednost koncentracije PM2.5 čestica primarno i PM10 čestica sekundarno u budućem vremenskom koraku $t+24h$. Na osnovu predviđene vrednosti PM2.5, primenom standardizovane SEPA metodologije, programski se izvodi AQI kategorija opasnosti (Odličan / Dobar / Prihvatljiv / Zagađen / Jako zagađen) bez dodatnog treniranja modela.

4. Metodologija

Centralna ideja projekta jeste uporedna analiza različitih algoritama nad istim skupom podataka. Oba člana tima treniraju regresione modele za isti zadatak (predikcija zagađenosti vazduha za $t+24h$), ali koriste različite pristupe.

Faza 1: Priprema i obrada podataka

Ova faza obuhvata sledeće:

- Čišćenje podataka: Interpolacija nedostajucih vrednosti u vremenskim serijama.
- Normalizacija: Skaliranje atributa u opseg $[0,1]$ primenom MinMaxScaler-a.
- Feature Engineering (klizni prozor): Za svaki vremenski korak t kreiraju se lagovani atributi PM2.5 i PM10 za prethodnih 48 sati (lag_1h, lag_2h, ..., lag_48h), kao i temporalni atributi (hour, month, day_of_week) koji modelima pomažu da preponaju i nauče dnevne saobraćajnešpicevei period i trajanje grejne sezone.
- Podela skupa: Time-Series Split (70% trening podaci: od juna 2016. do juna 2023, 20% validacioni skup podataka: od juna 2023. do juna 2025. i 10% test podaci: od juna 2025. do juna 2026). Bez nasumičnog mešanja kako bi se sprečilo curenje podataka iz budućnosti.

Faza 2: Regresiona predikcija Modul 1

XGBoost (eXtreme Gradient Boosting) je ansambl algoritam zasnovan na stablima odlučivanja. Ideja ansambla je sledeća: umesto jednog snažnog modela, trenira se veliki broj jednostavnih stabala odlučivanja, pri čemu se svako naredno stablo, umesto da ponovo uči od početka, fokusira isključivo na greškama koje je prethodno stablo napravilo i pokušava da ih ispravi. Ovaj iterativni postupak zove se gradijentni busting i daje modelu izuzetnu preciznost na tabelarnim podacima sa velikim brojem atributa.

LightGBM (Light Gradient Boosting Machine) funkcionišepo istom principu kao i XGBoost, ali koristi optimizovanu internu strukturu (leaf-wise rast stabla umesto level-wise) koja ga čini značajno bržim na velikim skupovima podataka. S obzirom na to da projekat ukupno broji preko 2.450.000 instanci, LightGBM predstavlja praktičnu alternativu koja se trenira i do 10 puta brže.

Oba modela se treniraju i međusobno porede. Bolji od njih ulazi u finalnu uporednu evaluaciju sa KNN i LSTM modelima.

Faza 2: Regresiona predikcija Modul 2

KNN Regressor (K-Nearest Neighbors) funkcioniše na principu analogije: za novi trenutak t pronalazi K najbližnjih istorijskih primera (po vrednostima polutanata i vremenskih atributa) i

kao predikciju vraća srednju vrednost PM2.5 tih K suseda. Vrednost K se određuje cross-validacijom.

LSTM (Long Short-Term Memory) je duboka rekurentna neuronska mreža specijalizovana za sekvencijalne podatke. Kroz mehanizam memorijskih kapija (forget gate, input gate, output gate) model selektivno pamti dugoročne trendove u kretanju zagađenja. Ulaz je matrica vrednosti za prethodnih 48 sati, izlaz je predviđena vrednost PM2.5 za $t+24h$.

Faza 3: Uporedna evaluacija

Svi modeli (XGBoost/LightGBM, KNN, LSTM) testiraju se na istom test skupu (jun 2024–jun 2025) i međusobno porede po RMSE, MAE i R^2 metrikama.

Ključno pitanje evaluacije: koji algoritam najpreciznije predviđa ekstremne pikove zagađenja? Rezultati se vizuelizuju grafički (stvarne vs. predviđene vrednosti, grafikon grešaka po modelu) i izlaze u vidu zaključaka o prednostima i ograničenjima svakog pristupa.

5. Način evaluacije

Validacija i testiranje svih razvijenih modela vršićese poštujući hronološki redosled i sekvencijalnu prirodu podataka primenom metode Time-Series Split. Celokupan skup podataka biće podeljen u odnosu 70% za trening, 20% za validacioni skup i 10% za test skup. Da bi se sprečilo curenje podataka iz budućnosti u prošlost, modeli će se trenirati na prvih 70% hronološki poređanih podataka, dok će se validacija izvršiti na narednih 20% podataka i testiranje raditi na preostalih 10% najsvežijih podataka.

Evaluacija modela se vrši sledećim precizno odabranim metricama performansi:

Za regresione modele:

1. RMSE (Root Mean Squared Error): Primarna metrika evaluacije. Zbog kvadriranja razlika između predviđenih i stvarnih vrednosti, RMSE drastično oštrije kažnjava veća odstupanja.
2. MAE (Mean Absolute Error): Pruža linearnu i lako razumljivu ocenu prosečne greške modela izraženu direktno u mikrogramima ($\mu g/m^3$).
3. R^2 Score (Koeficijent determinacije): Pokazuje procenat varijanse ciljne promenljive koji je uspešno objašnjen i pokriven od strane našeg prediktivnog modela.

6. Tehnologije

- Programski jezik: Python 3.10+
- Manipulacija i obrada podataka: Pandas, NumPy, SciPy
- Mašinsko i duboko učenje: Scikit-Learn, XGBoost/LightGBM, TensorFlow i Keras
- Korisnički interfejs i vizuelizacija: Plotly, Matplotlib, Seaborn
- Razvojno okruženje: VS Code

7. Primeri gotovih rešenja

1. [European Air Quality Index \(EEA\)](#)– Zvanični interaktivni sistem Evropske agencije za zaštitu životne sredine za prostorno-vremensku analizu i kategorizaciju aerozagađenja na nivou cele Evrope
2. [Air Quality Prediction LSTM & Machine Learning Systems](#)– Naučni i open-source repozitorijumi na GitHub platformi koji prikazuju uspešne primene dubokih neuronskih mreža i ansambl modela na sekvencijalnim ekološkim podacima

8. Relevantna literatura

1. Mitchell, T. M. (1998). Machine Learning. WCB/McGraw-Hill.
2. Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation, 9(8), 1735-1780.
3. Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference.
4. Russell, S., & Norvig, P. (2010). Artificial Intelligence: A Modern Approach (3rd ed.). Pearson.
5. Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NIPS 2017. <https://papers.nips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html>
6. Fix, E., Hodges, J. L. (1951). Discriminatory Analysis, Nonparametric Discrimination: Consistency Properties. USAF School of Aviation Medicine.
7. Agencija za zaštitu životne sredine (SEPA) - Zvanična Metodologija za izračunavanje i definisanje klasa opšteg Indeksa kvaliteta vazduha u Republici Srbiji. Ministarstvo zaštite životne sredine. www.sepa.gov.rs
8. Open-Meteo Historical Air Quality API — Dokumentacija izvora podataka koriscenih u projektu: <https://open-meteo.com/en/docs/air-quality-api>